

Inteligência Artificial

Aula 10 - vídeo 2 - Regressão Linear e Logística

João C. P. da Silva


Dept. Ciência da Computação - UFRJ

28 de outubro de 2020

Gradiente Descendente

- Algoritmo mais geral, usado em outros algoritmos de aprendizado de máquina.
- Usado para minimizar vários tipos de função.
- Considere uma função (qualquer) $J(\theta_0, \theta_1)$, onde estamos interessados em $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$.
 - Inicie com algum θ_0, θ_1 (por exemplo, $\theta_0 = \theta_1 = 0$)
 - Altere os valores de θ_0, θ_1 para reduzir $J(\theta_0, \theta_1)$ até atingir um mínimo.

Gradiente Descendente




Gradiente Descendente

- Repetir até convergir:
 - $temp_0 := \theta_0 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0}$
 - $temp_1 := \theta_1 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1}$
 - $\theta_0 := temp_0$
 - $\theta_1 := temp_1$
- α : taxa de aprendizado (learning rate). Determina o *tamanho do passo* que estamos dando.
- Note que θ_0 e θ_1 são atualizados simultaneamente.

Gradiente Descendente

Considere que queremos $\min_{\theta_1} J(\theta_1)$.



$$\theta_1 := \theta_1 - \alpha \frac{dJ(\theta_1)}{d\theta_1}$$

- $\frac{dJ(\theta_1)}{d\theta_1} > 0 : \theta_1 := \theta_1 - \alpha(+)= \theta_1 - \alpha(\dots)$
- $\frac{dJ(\theta_1)}{d\theta_1} < 0 : \theta_1 := \theta_1 - \alpha(-)= \theta_1 + \alpha(\dots)$

Gradiente Descendente para Regressão Linear

- **Regressão Linear**

- $Y = \theta_0 + \theta_1 * X$

- $J(\theta_0, \theta_1) = \sum_{i=1}^n (y_{i_{real}} - y_{i_{previsto}})^2 = \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))^2$

Gradiente Descendente para Regressão Linear

- **Regressão Linear**

- $Y = \theta_0 + \theta_1 * X$

- $J(\theta_0, \theta_1) = \sum_{i=1}^n (y_{i_{real}} - y_{i_{previsto}})^2 = \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))^2$

- Erro Quadrático Médio:

$$J(\theta_0, \theta_1) = \frac{1}{2n} \sum_{i=1}^n (y_{i_{real}} - y_{i_{previsto}})^2 = \frac{1}{2n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))^2$$

Gradiente Descendente para Regressão Linear

- **Regressão Linear**

- $Y = \theta_0 + \theta_1 * X$

- $J(\theta_0, \theta_1) = \sum_{i=1}^n (y_{i_{real}} - y_{i_{previsto}})^2 = \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))^2$

- Erro Quadrático Médio:

$$J(\theta_0, \theta_1) = \frac{1}{2n} \sum_{i=1}^n (y_{i_{real}} - y_{i_{previsto}})^2 = \frac{1}{2n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))^2$$

Usar Gradiente Descendente para minimizar o Erro Quadrático Médio

- **Gradiente Descendente**

- Repetir até convergir:

- $temp_0 := \theta_0 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0}$

- $temp_1 := \theta_1 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1}$

- $\theta_0 := temp_0$


- $\theta_1 := temp_1$

Gradiente Descendente para Regressão Linear

- $\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{1}{n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))$
- $\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{1}{n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0)) * x_i$
- Repetir até convergir:
 - $temp_0 := \theta_0 - \alpha * \frac{1}{n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0))$
 - $temp_1 := \theta_1 - \alpha * \frac{1}{n} \sum_{i=1}^n (y_i - (\theta_1 * x_i + \theta_0)) * x_i$
 - $\theta_0 := temp_0$
 - $\theta_1 := temp_1$


Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):




Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):




Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):




Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):




Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):



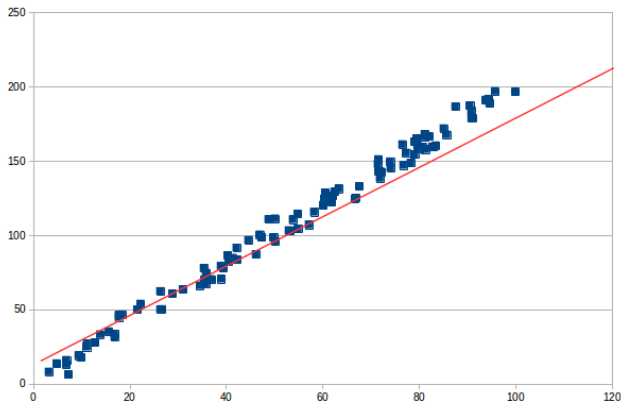
Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):




Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):



Gradiente Descendente para Regressão Linear

A função de custo para a regressão linear é uma *função convexa* (possui 1 ótimo global e nenhum ótimo local):



Regressão Linear com Múltiplas Variáveis

| X | Y |
|---------------|---------------|
| 95.724162408 | 197.179636092 |
| 35.7576189281 | 67.5906695414 |
| 28.8168474238 | 60.8541328206 |
| 99.9584813087 | 196.907396981 |
| 66.8097483121 | 125.311128524 |
| 58.2156926413 | 115.785784589 |
| 53.8210763379 | 110.762772705 |
| 81.2960821704 | 157.98528569 |
| 80.6486970595 | 159.61941373 |
| 78.2528136925 | 149.003865539 |

$$y = h_{\theta}(x) = \theta_0 + \theta_1 x$$

Regressão Linear com Múltiplas Variáveis

| X_1 | X_2 | X_3 | Y |
|---------------|-------|-------|---------------|
| 95.724162408 | 5 | 45.08 | 197.179636092 |
| 35.7576189281 | 3 | 34.32 | 67.5906695414 |
| 28.8168474238 | 3 | 11.12 | 60.8541328206 |
| 99.9584813087 | 2 | 32.32 | 196.907396981 |
| 66.8097483121 | 7 | 67.76 | 125.311128524 |
| 58.2156926413 | 1 | 21.21 | 115.785784589 |
| 53.8210763379 | 2 | 44.76 | 110.762772705 |
| 81.2960821704 | 0 | 55.32 | 157.98528569 |
| 80.6486970595 | 6 | 2.21 | 159.61941373 |
| 78.2528136925 | 4 | 66.54 | 149.003865539 |

- n : número de features. Na tabela, $n = 3$.
- $x^{(i)}$: entrada do i -ésimo exemplo de treinamento. Exemplo:
 $x^{(2)} = [35.7576189281, 3, 34.32]$
- $x_j^{(i)}$: valor da j -ésima feature no i -ésimo exemplo de treinamento. Exemplo:
 $x_3^{(2)} = 34.32$

Regressão Linear com Múltiplas Variáveis

| X_1 | X_2 | X_3 | Y |
|---------------|-------|-------|---------------|
| 95.724162408 | 5 | 45.08 | 197.179636092 |
| 35.7576189281 | 3 | 34.32 | 67.5906695414 |
| 28.8168474238 | 3 | 11.12 | 60.8541328206 |
| 99.9584813087 | 2 | 32.32 | 196.907396981 |
| 66.8097483121 | 7 | 67.76 | 125.311128524 |
| 58.2156926413 | 1 | 21.21 | 115.785784589 |
| 53.8210763379 | 2 | 44.76 | 110.762772705 |
| 81.2960821704 | 0 | 55.32 | 157.98528569 |
| 80.6486970595 | 6 | 2.21 | 159.61941373 |
| 78.2528136925 | 4 | 66.54 | 149.003865539 |

Antes:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

E agora?

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$$

Generalizando

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

Regressão Linear com Múltiplas Variáveis

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Considere $x_0 = 1$ ($x_0^{(i)} = 1$). Logo: $h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$

Fazendo: $x = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$ e $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$

temos: $h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n = [\theta_0, \theta_1, \cdots, \theta_n] \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} = \theta^T x$

Regressão Linear com Múltiplas Variáveis: $h_{\theta}(x) = \theta^T x$

Regressão Linear com Múltiplas Variáveis - Gradiente Descendente

- Hipótese

$$h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

- Parâmetros: $\theta : \theta_0, \theta_1, \cdots, \theta_n$

- Função de Custo: $J(\theta) = J(\theta_0, \theta_1, \cdots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Gradiente Descendente


- Repetir até convergir:

- $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \cdots, \theta_n) = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$

- Atualização simultânea.

Normalização


- Normalizando as features: diferentes features fiquem na mesma escala.
- x_1 variando de 0-2000 e x_2 variando de 1-5.
- $x_1 = \frac{x_1}{2000}$ e $x_2 = \frac{x_2}{5}$
- Ter uma convergência mais rápida.



- **Mean Normalization:** $x_i = \frac{x_i - \mu_i}{total}$ ($x_1 = \frac{x_1 - 1000}{2000}$ e $x_2 = \frac{x_2 - 2}{5}$)
- Toda feature: aproximadamente $-1 \leq x_i \leq 1$

Gradiente Descendente

- $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
- Como saber se o gradiente descendente está funcionando corretamente e como escolher α ?



- $J(\theta)$ deve decrescer a cada iteração.
- Se $J(\theta)$ estiver crescendo, utilize um α menor. Isso pode retardar a convergência. ($\alpha = \dots, 0.001, \dots, 0.01, \dots, 0.1, \dots$)

Inteligência Artificial

Aula 10 - vídeo 2 - Regressão Linear e Logística

João C. P. da Silva

Dept. Ciência da Computação - UFRJ

28 de outubro de 2020