

# Inteligência Artificial


## Aula 10 - vídeo 3 - Regressão Linear e Logística

João C. P. da Silva

Dept. Ciência da Computação - UFRJ


28 de outubro de 2020

# Classificação - Regressão Logística




- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$

# Classificação - Regressão Logística




- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$

# Classificação - Regressão Logística




- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$

# Classificação - Regressão Logística




- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$

# Classificação - Regressão Logística



- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$

# Classificação - Regressão Logística




- Limiar de classificação da saída  $h_{\theta}(x)$  em 0.5:
  - Se  $h_{\theta}(x) \geq 0.5$ , faça  $y = 1$
  - Se  $h_{\theta}(x) < 0.5$ , faça  $y = 0$
- Não parece ser uma boa ideia usar regressão linear para problemas de classificação.

# Classificação - Regressão Logística

- Note que  $y \in \{0, 1\}$ , mas  $h_{\theta}(x)$  pode ser  $> 1$  ou  $< 0$
- **Regressão Logística:**  $0 \leq h_{\theta}(x) \leq 1$
- Para isso, nossa hipótese  $h_{\theta}(x) = \theta^T x$  é transformado na hipótese  $h_{\theta}(x) = g(\theta^T x)$ , onde  $g(z) = \frac{1}{1+e^{-z}}$  é a função *sigmoide/logística*. Logo,

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$





# Classificação - Regressão Logística

**Interpretação de  $h_{\theta}(x)$**  : probabilidade estimada que  $y = 1$  dado o input  $x$ .

Ou seja,  $h_{\theta}(x) = P(y = 1 \mid x; \theta)$ .


Como consequência,  $P(y = 0 \mid x; \theta) = 1 - P(y = 1 \mid x; \theta)$

## Exemplo

$$\text{Se } x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ tam.tumor \end{bmatrix}$$

$h_{\theta}(x) = 0.7$  significa que existe uma chance de 70% do tumor ser maligno.


# Classificação - Regressão Logística



- Note que:
  - Se  $h_{\theta}(x) = g(\theta^T x) \geq 0.5$ , prevemos  $y = 1$
  - Se  $h_{\theta}(x) = g(\theta^T x) < 0.5$ , prevemos  $y = 0$
- Mas
  - $g(\theta^T x) \geq 0.5$  sempre que  $\theta^T x \geq 0$  e
  - $g(\theta^T x) < 0.5$  sempre que  $\theta^T x < 0$

# Classificação - Regressão Logística


## Exemplo



- Temos  $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$
- Considere os parâmetros  $\theta_0 = -3, \theta_1 = 1, \theta_2 = 1$
- Logo, teremos  $y = 1$  se  $-3 + x_1 + x_2 \geq 0$ , ou,  $x_1 + x_2 \geq 3$

# Classificação - Regressão Logística

## Exemplo



- Temos  $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$
- Considere os parâmetros  $\theta_0 = -3, \theta_1 = 1, \theta_2 = 1$
- Logo, teremos  $y = 1$  se  $-3 + x_1 + x_2 \geq 0$ , ou,  $x_1 + x_2 \geq 3$
- A equação  $x_1 + x_2 = 3$  corresponde a  $h_{\theta}(x) = 0.5$  (Decision Boundary)

# Classificação - Função Custo

- Conjunto de treinamento:  $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$

- $x = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}, x_0 = 1, y \in \{0, 1\}$

- $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$

- Como escolher os parâmetros  $\theta$ ?


- Regressão Linear:**  $J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$

- Usar esta função para regressão logística, podemos ter vários mínimos locais por causa de  $h_{\theta}(x)$ . ( $J(\theta)$  é **não convexa**).

- Regressão Logística:**  $\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{se } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{se } y = 0 \end{cases}$


# Classificação - Função Custo

**Regressão Logística:**  $Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{se } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{se } y = 0 \end{cases}$



# Classificação - Função Custo

**Regressão Logística:**  $Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{se } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{se } y = 0 \end{cases}$



# Classificação - Função Custo

**Regressão Logística:**  $Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{se } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{se } y = 0 \end{cases}$

Uma forma equivalente de escrever o custo:

$$Cost(h_{\theta}(x), y) = -y * \log(h_{\theta}(x)) - ((1 - y) * \log(1 - h_{\theta}(x)))$$

Então:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} * \log(h_{\theta}(x^{(i)})) + ((1 - y^{(i)}) * \log(1 - h_{\theta}(x^{(i)})))$$

Queremos determinar os parâmetros  $\theta$  que minimizam  $J(\theta)$  e fazer previsões para novos valores de  $x$  usando a fórmula  $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$



# Classificação - Função Custo

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} * \log(h_{\theta}(x^{(i)})) + ((1 - y^{(i)}) * \log(1 - h_{\theta}(x^{(i)})))$$

Para determinar os parâmetros  $\theta$  que minimizam  $J(\theta)$  usamos **gradiente descendente**:

- Repetir até convergir:
  - $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
- Atualização simultânea.

# Inteligência Artificial

## Aula 10 - vídeo 3 - Regressão Linear e Logística

João C. P. da Silva

Dept. Ciência da Computação - UFRJ

28 de outubro de 2020